

DOCUMENTACIÓN TÉCNICA

Sistema de Seguimiento de Recaudo y Consolidado de Bancos

1. Introducción y Propósito

Este documento describe de forma exhaustiva la arquitectura, lógica de negocio, flujo de datos y decisiones técnicas de dos módulos Python/Streamlit desarrollados para el área de tesorería:

- Seguimiento Recaudo Diario – consolida los movimientos de crédito/recaudo presentes en los archivos Excel de extractos bancarios y genera un reporte diario por banco con totales acumulados mensuales.
- Consolidado Bancos – procesa los mismos archivos Excel y genera un pivot por categoría/concepto cruzado por banco, con una hoja por mes y una hoja de totales globales.

Ambos módulos comparten gran parte de la lógica de lectura y normalización de datos, diferenciándose principalmente en el tipo de pivot de salida y en el criterio de filtrado (recaudo vs. todos los movimientos).

2. Arquitectura General

2.1 Diagrama de capas

El sistema opera en una sola capa (cliente/servidor integrado en Streamlit), sin base de datos ni API externa. Todo el procesamiento ocurre en memoria, en el servidor Streamlit.

Capa	Componente	Responsabilidad
Capa de presentación	Streamlit UI	Carga de archivos, widgets de configuración, tablas interactivas, botón de descarga.
Capa de lógica	Python puro (pandas, openpyxl)	Normalización, detección de encabezados, parseo de

		montos, filtrado de recaudo, pivots.
Capa de entrada	Excel / ZIP	Extractos bancarios con hojas mensuales (ej. Enero, Febrero...).
Capa de salida	Excel (.xlsx)	Archivo con una hoja por mes más hoja Total; estilos de color incluidos.

2.2 Tecnologías y dependencias

Paquete	Versión	Propósito
streamlit	≥1.32	Framework web para la interfaz de usuario
pandas	≥2.0	Manipulación y transformación de DataFrames
openpyxl	≥3.1	Lectura y escritura de archivos .xlsx con estilos
re	stdlib	Expresiones regulares para normalización de texto
unicodedata	stdlib	Eliminación de tildes y caracteres especiales
zipfile	stdlib	Descompresión de archivos ZIP
io	stdlib	Manejo de buffers en memoria (BytesIO)

3. Estructura de Archivos del Proyecto

- seguimiento-recaudo/
 - |— app.py # Módulo principal (Streamlit multi-página)
 - |— pages/
 - |— 1_Limpiador_Duplicados.py # Página secundaria (Limpiador)
 - |— .streamlit/
 - |— config.toml # maxUploadSize=500, maxMessageSize=500
- attached_assets/
 - |— Seguimientorecaudo_*.py # Código fuente del módulo Recaudo
 - |— consolidadobancos_*.py # Código fuente del módulo Consolidado

El sistema corre con el workflow 'Seguimiento Recaudo' en el puerto 5000 de Replit, bajo el comando:

```
streamlit run app.py --server.port 5000 --server.address 0.0.0.0 --server.headless true
```

4. Módulo: Seguimiento Recaudo Diario

4.1 Propósito

Este módulo extrae exclusivamente los movimientos de recaudo/consignación de los extractos bancarios mensuales y los organiza en un pivot diario: filas = fechas, columnas = banco, con total diario y total acumulado del mes. El resultado se muestra en pantalla por pestañas y se puede descargar como Excel.

4.2 Flujo de procesamiento

- Paso 1: Carga de archivos: El usuario sube uno o varios Excel/ZIP. La función `cargar_excels()` filtra archivos de salida para evitar reprocesamiento circular.
- Paso 2: Lectura por hojas: `read_real_excel()` itera sobre las hojas del Excel; `es_hoja_mes()` descarta hojas que no sean meses (ej. 'Rec.Ene', 'Resumen').
- Paso 3: Detección de encabezado: `find_best_header_row()` puntúa cada una de las primeras 25 filas contando coincidencias con `HEADER_KEYWORDS` y selecciona la de mayor puntaje.
- Paso 4: Eliminación de repetidos: Elimina filas que repitan los mismos nombres de columna (práctica común en extractos bancarios con encabezado en cada página).
- Paso 5: Estandarización: `standardize_df()` mapea las columnas originales del banco a: Categoría, Concepto, Banco, Fecha, Valor.
- Paso 6: Parseo de montos: `parse_amount()` detecta y convierte formatos colombiano (232.000,50) y americano (1,234.56) al float correcto.
- Paso 7: Filtrado de recaudo: Aplica doble filtro: $Categoría \in \{\text{ingreso, crédito}\}$ AND Concepto contiene palabras clave de recaudo. Si el primer filtro no da resultados, usa solo el filtro de concepto.
- Paso 8: Pivoteo mensual: `build_pivot_mes()` agrupa por Fecha+Banco, pivota, añade Total Diario y Total Acumulado Mes (`cumsum`).

- Paso 9: Exportación Excel: `build_excel()` crea un Workbook con una hoja por mes + hoja 'Total', con estilos de color para fines de semana y filas alternas.

4.3 Constantes y parámetros de configuración

Constante	Tipo	Descripción
HOJAS_MESES	set de 12 strings	Nombres de meses normalizados para filtrar hojas
HEADER_KEYWORDS	set de ~20 strings	Palabras clave para detectar la fila de encabezado bancario
KEYWORDS_CATEGORIA	list[str]	Sinónimos de 'categoría de movimiento'
KEYWORDS_CONCEPTO	list[str]	Sinónimos de 'descripción/concepto del movimiento'
KEYWORDS_VALOR	list[str]	Sinónimos de 'monto/valor' (incluye 'vlr flujo', 'dcred')
KEYWORDS_FECHA	list[str]	Sinónimos de 'fecha' (incluye 'fec', 'date')
RECAUDO_KEYWORDS	list[str]	Palabras que identifican un movimiento de recaudo/consignación
NOMBRES_SALIDA	list[str]	Prefijos de archivos generados por el sistema (se excluyen de la entrada)
HEADER_COLOR	'1F4E79' (hex)	Azul oscuro para encabezados Excel
WEEKEND_BG	'FCE4D6' (hex)	Fondo naranja para filas de fin de semana
ALT_BG	'EBF3FB' (hex)	Fondo azul claro para filas pares
GRAND_TOTAL_BG	'163755' (hex)	Azul muy oscuro para la fila TOTAL

4.4 Descripción de funciones

`normalize(text)`

Convierte texto a minúsculas, elimina tildes con `unicodedata.normalize('NFKD')` y borra todo carácter que no sea alfanumérico. Uso: comparaciones robustas independientes de acentuación y capitalización.

`es_archivo_salida(nombre)`

Retorna True si el nombre del archivo contiene algún prefijo de archivo de salida (consolidadobancos, flujotesoreria, seguimientorecaudo). Previene que el sistema procese sus propios archivos de salida como entrada.

`es_hoja_mes(nombre_hoja)`

Normaliza el nombre de la hoja y verifica si contiene alguno de los 12 tokens de mes. Esto permite hoja 'Enero 2024', 'ENERO-1' o 'Mes Enero', pero excluye 'Rec.Ene'.

`find_column(columns, keywords)`

Busca entre las columnas del DataFrame la que mejor coincide con las palabras clave dadas, usando matching bidireccional ($\text{keyword} \subseteq \text{columna}$ OR $\text{columna} \subseteq \text{keyword}$). Retorna el nombre original de la columna o None.

`parse_amount(val)`

Parsea una cadena de texto a float detectando el formato de separadores:

- Ambos (punto y coma): si el punto está más a la derecha → americano (quitar comas); si la coma está más a la derecha → COP/europeo (quitar puntos, coma→punto).
- Solo punto: si todos los grupos post-punto tienen 3 dígitos → punto es miles.
- Solo coma: idem para coma. Retorna 0.0 en caso de error.

`score_header_row(row)`

Calcula cuántas celdas de la fila contienen al menos una de las palabras clave de HEADER_KEYWORDS. Usado internamente por `find_best_header_row()`.

`find_best_header_row(df_raw, max_search=25)`

Itera las primeras `max_search` filas del DataFrame crudo (sin encabezado) y devuelve el índice de la fila con mayor score. Soluciona el problema de extractos que tienen metadatos del banco en las primeras filas antes del encabezado real.

`read_real_excel(file)`

Lee SOLO las hojas de meses del Excel. Para cada hoja: detecta el encabezado con `find_best_header_row()`, parsea el DataFrame, elimina filas all-NaN y filas que repitan los encabezados. Retorna (DataFrame concatenado, lista de hojas, log diagnóstico).

`cargar_excels(uploads)`

Itera la lista de uploads de Streamlit. Descarta archivos de salida. Descomprime ZIPs y extrae los .xlsx/.xls internos. Retorna lista de tuplas (nombre, bytes).

`standardize_df(df, filename)`

Mapea las columnas originales del banco a las 5 columnas canónicas: Categoría, Concepto, Banco (derivado del nombre de archivo), Fecha, Valor. Normaliza fechas con `dayfirst=True` y elimina `timezone`. Retorna (DataFrame, dict de columnas detectadas).

`es_recaudo(concepto_str)`

Normaliza el concepto y verifica si contiene alguna palabra de `RECAUDO_KEYWORDS` (recaudo, ventas, consignacion, consig...).

`safe_val(v)`

Convierte `pd.Timestamp` a `datetime` nativo Python (requerido por `openpyxl`) y reemplaza `float NaN` por `0.0`.

`write_daily_sheet(ws, pivot, banco_cols)`

Escribe un pivot diario en una hoja `openpyxl` con: encabezados azul oscuro, fines de semana en naranja, filas alternas en azul claro, fila TOTAL en azul marino, formato `#,##0.00` para columnas de dinero, `DD/MM/YYYY` para fechas, paneles congelados en B2.

`build_pivot_mes(df_mes, banco_cols)`

Agrupar `df_mes` por Fecha y Banco, pivota (`index=Fecha`, `columns=Banco`, `values=Valor`), asegura que todos los bancos estén presentes, calcula Total Diario y Total Acumulado Mes.

`build_excel(data_por_mes, banco_cols)`

Crea un Workbook `openpyxl`. Llama `write_daily_sheet()` para cada mes. Agrega hoja 'Total' con todos los datos concatenados. Devuelve `BytesIO` listo para el botón de descarga.

`run()`

Función principal de Streamlit: configura la página, muestra el file uploader, orquesta todo el pipeline, muestra métricas (meses, bancos, total recaudo), despliega pestañas por mes y el botón de descarga.

4.5 Estructura del Excel de salida (Seguimiento Recaudo)

Cada hoja tiene la siguiente estructura de columnas:

Columna	Tipo	Descripción
Fecha	datetime	Fecha del movimiento (DD/MM/YYYY)
<Banco 1>	float	Suma de recaudos del banco en esa fecha
<Banco N>	float	Una columna por cada banco detectado
Total Diario	float	Suma de todos los bancos en la fecha
Total Acumulado Mes	float	Suma acumulada progresiva del mes

La última fila de cada hoja es TOTAL (fondo azul marino): suma de columnas de dinero, valor final del acumulado.

5. Módulo: Consolidado Bancos

5.1 Propósito

Este módulo procesa TODOS los movimientos de los extractos bancarios (sin filtrar por recaudo) y los consolida en un pivot por Categoría + Concepto cruzado con una columna por banco. Genera una hoja por mes y una hoja de totales, permitiendo analizar ingresos y egresos por tipo de movimiento.

5.2 Diferencias clave frente al módulo Recaudo

Aspecto	Seguimiento Recaudo	Consolidado Bancos
Hojas leídas	Solo hojas de mes (es_hoja_mes)	Todas las hojas del Excel
Filtro de filas	Solo recaudo/consignaciones	Todos los movimientos
Eje del pivot	index=Fecha (diario)	index=[Categoría, Concepto]
Columnas calculadas	Total Diario + Total Acumulado Mes	Total por concepto
Colores de fila	Fin de semana=naranja, alternas=azul	Ingreso=verde, Egreso=rojo, alternas=azul
Detección encabezado	find_best_header_row() (máx. score)	Primer is_header_row() (umbral fijo ≥ 4)

5.3 Flujo de procesamiento

- Paso 1: Carga de archivos: Idéntico al módulo Recaudo: cargar_excels() con filtro de archivos de salida.
- Paso 2: Lectura de Excel: read_real_excel() lee TODAS las hojas (no solo meses). Usa is_header_row() con umbral de ≥ 4 celdas cortas como criterio de encabezado.
- Paso 3: Estandarización: standardize_df() produce las mismas 5 columnas canónicas. El banco se infiere del nombre de archivo.
- Paso 4: Segmentación mensual: Si las fechas son válidas, agrupa en Mes_label (ej. 'Enero 2024'). Si no hay fechas, agrupa todo en 'Sin fecha'.

- Paso 5: Pivot por concepto: `build_pivot_concepto()` agrupa por Categoría+Concepto+Banco, pivota (columnas=Banco), calcula Total por fila.
- Paso 6: Escritura Excel: `write_concepto_sheet()` aplica colores según categoría: verde para ingresos, rojo para egresos, azul claro alterno para el resto.
- Paso 7: Hoja Total: Concatena todos los meses y genera un pivot global adicional.

5.4 Descripción de funciones exclusivas del Consolidado

`is_header_row(row)`

Criterio alternativo de detección: cuenta celdas de texto cortas (<30 caracteres). Si hay ≥ 4 , considera la fila como encabezado. Más simple que `find_best_header_row`, adecuado cuando las hojas no tienen metadatos previos al encabezado.

`clean_money(series)`

Versión simplificada para el Consolidado: aplica solo `str.replace` para '\$', ',' y espacios antes de `pd.to_numeric()`. A diferencia del Recaudo, no detecta formato COP.

`build_pivot_concepto(df_mes, banco_cols)`

Agrupa por Categoría+Concepto+Banco, pivota con columnas=Banco, añade columna Total. Ordena por Categoría+Concepto. Garantiza que todos los bancos tengan columna aunque no tengan movimientos en ese mes.

`write_concepto_sheet(ws, pivot, banco_cols)`

Escribe la hoja de concepto en `openpyxl`. Detecta si Categoría $\in$ {ingreso, crédito} $\rightarrow$ fondo verde; $\in$ {egreso, gasto, salida, débito} $\rightarrow$ fondo rojo; alterno $\rightarrow$ azul claro. Fila final TOTAL en azul marino. Paneles congelados en C2. Ancho de columna automático.

5.5 Estructura del Excel de salida (Consolidado Bancos)

Columna	Tipo	Descripción
Categoría	str	Tipo de movimiento (Ingreso, Egreso, etc.)
Concepto	str	Descripción o referencia del movimiento
<Banco 1>	float	Suma de montos del banco para este concepto
<Banco N>	float	Una columna por banco detectado
Total	float	Suma total de todos los bancos por concepto

6. Lógica Compartida entre Módulos

6.1 Normalización de texto

La función `normalize()` es el núcleo de todos los matching del sistema. Aplica tres transformaciones en cascada:

```
text = str(text).lower().strip()
text = unicodedata.normalize("NFKD", text).encode("ascii", "ignore").decode("ascii")
return re.sub(r"[^a-z0-9]", "", text)
```

- Paso 1: minúsculas y recorte de espacios.
- Paso 2: descomposición Unicode NFD → eliminar marcas diacríticas (tildes, ñ, ü...).
- Paso 3: mantener solo letras a-z y dígitos 0-9. Elimina espacios, guiones, puntos.

Resultado: 'Débito/Crédito' → 'debitocredito'. Permite comparar sin importar mayúsculas, tildes ni separadores.

6.2 Detección de columnas (`find_column`)

Implementa un matching bidireccional tolerante: la keyword puede estar contenida en el nombre de columna o el nombre de columna puede estar contenido en la keyword. Esto maneja variantes como:

- "vlr flujo" → detecta columna "Vlr. Flujo Caja" ($\text{keyword} \subseteq \text{col}$)
- "fecha" → detecta columna "Fec" ($\text{col} \subseteq \text{keyword}$)
- Las keywords se evalúan en orden de prioridad (las más específicas primero)

6.3 Parseo de montos COP/USD (`parse_amount`)

Colombia usa punto como separador de miles y coma como decimal, a diferencia del estándar americano. La función resuelve la ambigüedad con estas reglas:

Caso	Criterio de detección	Resultado
Solo punto	¿Todos los grupos tienen 3 dígitos?	Sí → miles (232.000 → 232000)
Solo coma	¿Todos los grupos tienen 3 dígitos?	Sí → miles; No → decimal (3,5 → 3.5)
Punto Y coma	¿El punto está más a la derecha?	Sí → americano (1,234.56); No → COP (1.234,56)
Sin separadores	Número entero puro	Conversión directa a float
Cadena vacía/error	nan, None, -, vacío	Retorna 0.0

6.4 Filtro de archivos de salida

Para evitar el procesamiento circular (que el Excel generado sea leído como entrada en la siguiente ejecución), la función `es_archivo_salida()` verifica que el nombre del archivo no contenga ninguno de los prefijos:

```
NOMBRES_SALIDA = ['consolidadobancos', 'flujotesoreria', 'seguimientorecaudo']
```

Este filtro se aplica tanto a archivos directamente subidos como a archivos extraídos de un ZIP.

7. Formatos de Entrada Soportados

7.1 Archivos aceptados

Extensión	Descripción	Motor de lectura
.xlsx	Excel moderno (Office 2007+)	Openpyxl nativo
.xls	Excel legacy (Office 97-2003)	Pandas con xlrd
.zip	Archivo comprimido	Extrae .xlsx/.xls internos automáticamente

7.2 Estructura esperada de un Excel bancario

Los archivos pueden tener cualquier número de hojas. El sistema filtra las hojas cuyos nombres contengan un mes (en el módulo Recaudo) o procesa todas (Consolidado). Dentro de cada hoja:

- Pueden existir filas de metadatos antes del encabezado real (nombre del banco, período, número de cuenta, etc.). El sistema las ignora automáticamente.
- El encabezado puede estar en cualquiera de las primeras 25 filas.
- Los nombres de columna pueden variar según el banco (p.ej. 'Vlr Flujo', 'Valor DC', 'Importe', 'Monto' son todos detectados como la columna de valor).
- Los montos pueden estar en formato COP (1.234.567,89) o americano (1,234,567.89).
- Las fechas pueden estar en formato DD/MM/YYYY o MM/DD/YYYY; pandas aplica dayfirst=True.

7.3 Limitaciones conocidas

- Archivos con contraseña o encriptación no son soportados.
- Hojas con datos en múltiples tablas separadas: solo se detecta la primera tabla.
- Archivos .csv o .txt no son aceptados directamente (deben convertirse a Excel primero).
- El tamaño máximo de upload es 500 MB (configurado en .streamlit/config.toml).

8. Interfaz de Usuario (Streamlit)

8.1 Módulo Seguimiento Recaudo

Componente	Descripción
Título	 Seguimiento Recaudo Diario
Layout	wide (ancho completo de pantalla)
File uploader	Acepta .xlsx, .xls, .zip; múltiples archivos; key='sr_files'
Métricas (3 cols)	Meses encontrados · Bancos · Total recaudo \$
Expander 1	 Reporte de lectura: tabla con estado de cada archivo
Expander 2	 Diagnóstico detallado: log de hojas, columnas y fechas detectadas
Tabs por mes	Una pestaña por mes + pestaña  Total
Contenido de tab	DataFrame interactivo del pivot diario (hide_index=True)

Botón descarga	↓ Descargar Seguimiento Recaudo Diario (.xlsx)
----------------	--

8.2 Módulo Consolidado Bancos

Componente	Descripción
Título	Consolidado Bancos
File uploader	Idéntico al Recaudo; key='cb_files'
Expander	Reporte de lectura: tabla con Archivo, Filas, Estado
Info banner	N archivos a procesar · N mes(es) N banco(s)
Tabs	Una pestaña por mes (Mes Año) + 'Total'
Contenido	DataFrame del pivot Categoría+Concepto por banco
Botón descarga	Descargar Consolidado Bancos → Consolidado_Bancos.xlsx

9. Salida Excel – Estilos y Formato

9.1 Paleta de colores

Hex	Nombre	Uso
#1F4E79	Azul corporativo oscuro	Encabezados de columna
#163755	Azul marino	Fila TOTAL / GRAND TOTAL
#EBF3FB	Azul claro	Filas pares / alternas
#FCE4D6	Salmón/naranja	Filas de fin de semana (Recaudo)
#E2EFDA	Verde claro	Filas de categoría Ingreso (Consolidado)
#FCE4D6	Rojo claro	Filas de categoría Egreso (Consolidado)
#FFFFFF	Blanco	Filas impares estándar

9.2 Formatos de celda

Elemento	Valor	Contexto
Fechas	DD/MM/YYYY	Columna Fecha en el Recaudo
Montos	#,##0.00	Todas las columnas numéricas
Alineación \$	Derecha	Columnas de valor y totales
Alineación fecha	Centro	Columna Fecha
Panel congelado	B2 (Recaudo)	La columna Fecha y la fila de encabezado siempre visibles
Panel congelado	C2 (Consolidado)	Categoría+Concepto y encabezado siempre visibles
Borde	Thin, todos lados	Todas las celdas de datos y encabezado
Fuente encabezado	Bold, blanca, 10pt	Todos los encabezados de columna
Fuente TOTAL	Bold, blanca, 11pt	Fila de totales
Auto-ancho	Máx. 30/40 chars	Calculado por contenido real de cada columna

10. Manejo de Errores y Diagnóstico

10.1 Estrategia de errores

El sistema aplica el principio de 'fail soft': los errores en un archivo individual no detienen el procesamiento de los demás. Cada excepción se captura a nivel de archivo y se reporta en la tabla de diagnóstico.

10.2 Niveles de diagnóstico

Símbolo	Significado
 Omitida	Hoja no es mes (es_hoja_mes → False)
 Muy corta	Hoja tiene <2 filas de datos
 Leída	Hoja procesada correctamente; indica fila de header y primeras 6 columnas
 Sin datos	Hoja vacía tras limpiar filas all-NaN o filas de encabezado repetido
 Error	Excepción inesperada al parsear la hoja; se muestra el mensaje de error

10.3 Validaciones de negocio

- Si ningún archivo aporta datos → `st.warning('No se encontraron archivos de banco válidos.')`
- Si el DataFrame final está vacío tras filtrar recaudo → `st.warning` con instrucción de revisar diagnóstico.
- Si no hay fechas válidas tras filtrar NaT → `st.warning('No hay registros con fecha válida.')`
- Si un banco no tiene movimientos en un mes → su columna aparece con valor 0.0 (no se elimina).
- Errores críticos del pipeline principal → `st.error()` + `st.exception()` para stack trace visible.

11. Configuración del Entorno (Replit)

11.1 Workflow

```
Nombre: "Seguimiento Recaudo"
Comando: cd seguimiento-recaudo && streamlit run app.py \
  --server.port 5000 \
  --server.address 0.0.0.0 \
  --server.headless true
```

11.2 .streamlit/config.toml

```
[server]
maxUploadSize = 500
maxMessageSize = 500
```

Estos valores permiten subir archivos Excel de hasta 500 MB, necesario para extractos anuales de múltiples bancos.

11.3 Variables de entorno

SESSION_SECRET: utilizado por el middleware de sesión de Streamlit. Configurado como secreto de Replit (no se expone en el código fuente).